

1 Implementation - HMM

Exercice 1.2

Tout d'abord, notons π la distribution initiale de q_0 , $A = (p(q_t = i, q_{t+1} = j))_{i,j}$ et $\theta = ((\pi_j)_j, (\mu_j)_j, (\Sigma_j)_{j=1}^K, A)$ l'ensemble des paramètres du modèle. Commençons par écrire le "complete log-likelihood" :

$$l_c = \ln(p_\theta(x, z)) = \ln \left[\prod_{t=1}^T p_\theta(u_t, q_t) \right]$$

$$= \sum_{j=1}^K \mathbb{I}(q_t = j) \ln \pi_j + \sum_{t=0}^{T-1} \sum_{i,j=1}^K \mathbb{I}(q_{t+1} = j, q_t = i) \ln(A_{i,j}) + \sum_{t=0}^T \sum_{i=1}^K \mathbb{I}(q_t = i) \ln(\mathcal{N}(u_t | \mu_j, \Sigma_j))$$

Afin de déterminer l'E-step, nous passons à l'espérance conditionnelle dans l'expression précédente :


$$\mathbb{E}_{Q|U,\theta} [\log(p_\theta(u, q))] = \sum_{j=1}^K p(q_0 = j | u, \theta) \ln \pi_j + \sum_{t=0}^{T-1} \sum_{i,j=1}^K p(q_{t+1} = j, q_t = i | u, \theta) \ln(A_{i,j}) + \sum_{t=0}^T \sum_{j=1}^K p(q_t = j | u, \theta) \ln(\mathcal{N}(u_t | \mu_j, \Sigma_j))$$

Désormais, attaquons-nous à l'M-step. Elle consiste à maximiser la quantité précédente en $\theta = ((\pi_j)_j, (\mu_j)_j, (\Sigma_j)_j, A)$. Comme nous souhaitons maximiser des quantités indépendantes, on peut majorer chacun des termes indépendamment. En reprenant la démarche du TP précédent, ainsi que la convention $0/0 = 0$, on trouve :


$$\pi'_j = \frac{p(q_0 = j | u, \theta)}{\sum_{i=1}^K p(q_0 = i | u, \theta)}; \quad \mu'_j = \frac{\sum_{t=0}^T p(q_t = j | u, \theta) u_t}{\sum_{t=0}^T p(q_t = j | u, \theta)}; \quad \Sigma'_j = \frac{\sum_{t=0}^T p(q_t = j | u, \theta) \|u_t - \mu_{j,t}\|^2}{\sum_{t=0}^T p(q_t = j | u, \theta)}$$

Intéressons-nous à la matrice de transition A . Comme la somme des éléments de chaque ligne est égale à 1, nous étudions le lagrangien $\mathcal{L}(A, \lambda) := \sum_{i,j=1}^K p(q_{t+1} = j, q_t = i | u, \theta) \ln(A_{i,j}) - \lambda^T (A\mathbb{1} - \mathbb{1})$. Comme $A \mapsto \mathcal{L}(A, \lambda)$ est concave, il suffit de déterminer un point d'annulation du gradient. Cela se produit lorsque $\lambda_i = \sum_t \sum_{j=1}^K p(q_{t+1} = j, q_t = i | u, \theta)$. En utilisant la contrainte $A\mathbb{1} = \mathbb{1}$, on obtient la valeur de λ_i . En définitif, $A'_{i,j} = \frac{\sum_t p(q_{t+1}=j, q_t=i | u, \theta)}{\sum_t \sum_{j'=1}^K p(q_{t+1}=j', q_t=i | u, \theta)}$.

Exercice 1.4



(a) EM - GMM



(b) EM - HMM

Exercice 1.5

Log-likelihood	EM - GMM	EM - HMM
Unnormalized Train	-3022	-2155
Normalized Train	-6.04	-4.31
Unnormalized Test	-3077	-2202
Normalized Test	-6.15	-4.41

plus petite que celle du modèle HMM. En effet, contrairement au modèle GMM, le modèle HMM introduit une dépendance markovienne entre les variables cachées q_t . Cela lui permet de mieux s'adapter aux observations, donc de produire un modèle plus adapté aux u_t . Par conséquent, il est cohérent que le likelihood de HMM soit plus grand que celui de GMM.

Nous constatons que l'entropie du modèle GMM est